

LLMs

Fundamentos e Implementación Local

Escuela de Verano · CUCEI-UDG


30 junio 2026




El momento que lo cambió todo



COMPARACIÓN: TIEMPO PARA ALCANZAR 100M USUARIOS



**Mucha adopción,
poca comprensión**



IA no es sinónimo de LLM

Imaginario popular



IA todopoderosa

Consciencia, voluntad, toma de decisiones como humanos



Tecnología del futuro

Ficción, robots, escenarios extremos



Solución mágica

Resuelve todo sin esfuerzo ni contexto



VS

Lo que usamos hoy



Escribe un resumen sobre la IA...

La inteligencia artificial (IA) es el **campo**.

La inteligencia artificial permite a las **máquinas**...

La IA se aplica en visión por **computadora**...

...

¿Cómo funciona?

Entrada



La

IA

es

el


campo

...



Siguiente token
"campo"

Predice el siguiente token más probable



IA > ML > Deep Learning > GenAI > **LLMs**



El hype mezcló el vocabulario



Hoy vamos a ser precisos

El árbol genealógico



Cada avance construye sobre el anterior. ChatGPT no es magia, es el resultado de décadas de investigación.

Predicción de tokens

Contexto anterior → siguiente token probable



Token ≠ palabra

Las palabras se dividen en fragmentos (tokens).

Ejemplo: inteligencia → "intel" + "igencia"



Context window = memoria de trabajo

Es la cantidad máxima de tokens anteriores que el modelo puede ver para predecir el siguiente.




Temperature = variabilidad

Controla qué tan deterministas o creativas son las respuestas del modelo.

TEMPERATURE

0 = consistente

1.5 = creativo



Alucinación = texto falso con confianza



Los LLMs no “saben”, predicen. Pueden sonar correctos y estar completamente equivocados.

Dos respuestas al problema



RAG: buscar primero, generar después



Menos alucinaciones, más verdad: **trae hechos del exterior.**



Razonamiento: pasos antes de responder




Menos errores lógicos, más coherencia: **piensa antes de responder.**



Ambos se implementan con **arquitectura**, no con magia

Agente = LLM + herramientas



IA local en tu laptop



Modelos abiertos

Llama · Mistral · Gemma · Qwen · Phi · Mixtral · ...



Motores locales

llama.cpp · GGUF · CPU / GPU · CuBLAS · Metal



Ollama / LM Studio

Descargar · Gestionar · Ejecutar · Servir



Tu laptop (tú tienes el control)

CPU / GPU · RAM · Almacenamiento



Tus apps Python

LangChain · LlamaIndex · CrewAI · FastAPI · Gradio · ...



Sin API key · Sin enviar tus datos · Sin costo por consulta

Ollama simplifica la ejecución



Sin API key



Sin enviar
tus datos



Sin costo
por consulta



¿Qué significa 7B?




Parámetros = pesos aprendidos

Son los valores internos que el modelo ajusta durante el entrenamiento.



B = billion
= mil millones
no billón en español



3B: 4-8 GB RAM

Ligero y rápido.
Ideal para laptops básicas.



7B/8B: 8-16 GB RAM

Mejor equilibrio calidad / recursos.
Sweet spot para la mayoría.



70B+: hardware especializado

Requiere GPUs potentes o múltiples.
Más costoso y complejo.



Calidad ≠ tamaño lineal

Arquitectura, datos y entrenamiento importan más.



Más grande no siempre es mejor (ni necesario). Elige el modelo adecuado para tu hardware y tu caso de uso.

De cero a agente en 80 minutos

🕒 Teoría clara → Demos prácticas → Agente integrado

```
$ python taller_llm.py  
> Cargando modelo local...  
> Modelo listo.  
> ¡Listo para construir!  
$ _
```

1



Generación

``01_generacion_basica.py``

2



Chat

``02_chat_conversacion.py``

3



JSON

``03_salida_estructurada.py``

4



Embeddings

``04_embeddings_similitud.py``

5



RAG

``05_rag_simple.py``

6



Agente

``06_agente_con_herramientas.py``

Integra todo: decide,
usa herramientas,
obtiene datos y responde.

El modelo completa
texto a partir de un prompt.

Conversación
multi-turno con el modelo.

Respuestas estructuradas
en formato JSON.

Representaciones vectoriales
y similitud semántica.

Recuperación de información
y respuesta aumentada.

Agente con herramientas
que resuelve tareas reales.



Cada paso construye el siguiente. Al final, tienes tu propio **agente funcional**.



El futuro ya corre en tu laptop

 Ya puedes construir:



Chatbot sobre
tus apuntes



Extractor de datos
estructurados



Clasificador
de tickets



Agente con
herramientas



github.com/zamax14/Curso-LLM



Código listo para usar



Ejemplos prácticos



Construye tus propias apps



¡Dale una estrella!



```
ollama run llama3.2

>>> Hola! ¿En qué puedo ayudarte?

>>> ,list models

NAME          SIZE
llama3.2:7b   4.7 GB
mistral:7b    4.1 GB
phi3:mini     2.3 GB

>>> ¿Listo para construir?
Sí. Vamos a crear.

>>> |
```

Tu toolkit de IA local

