

LLMs

Fundamentos e Implementación Local

Escuela de Verano · CUCEI-UDG


30 junio 2026




El momento que lo cambió todo



COMPARACIÓN: TIEMPO PARA ALCANZAR 100M USUARIOS



**Mucha adopción,
poca comprensión**



IA no es sinónimo de LLM

Imaginario popular



IA todopoderosa

Consciencia, voluntad, toma de decisiones como humanos



Tecnología del futuro

Ficción, robots, escenarios extremos



Solución mágica

Resuelve todo sin esfuerzo ni contexto



VS

Lo que usamos hoy



Escribe un resumen sobre la IA...

La inteligencia artificial (IA) es el **campo**.

La inteligencia artificial permite a las **máquinas**...

La IA se aplica en visión por **computadora**...

...

¿Cómo funciona?

Entrada



La

IA

es

el


campo

...



Siguiente token
"campo"

Predice el siguiente token más probable



IA > ML > Deep Learning > GenAI > **LLMs**



El hype mezcló el vocabulario



Hoy vamos a ser precisos

El árbol genealógico



Cada avance construye sobre el anterior. ChatGPT no es magia, es el resultado de décadas de investigación.

Predicción de tokens

Contexto anterior → siguiente token probable



Token ≠ palabra

Las palabras se dividen en fragmentos (tokens).

Ejemplo: inteligencia → "intel" + "igencia"



Context window = memoria de trabajo

Es la cantidad máxima de tokens anteriores que el modelo puede ver para predecir el siguiente.



Temperature = variabilidad

Controla qué tan deterministas o creativas son las respuestas del modelo.

TEMPERATURE

0 = consistente

1.5 = creativo



Alucinación = texto falso con confianza



Los LLMs no “saben”, predicen. Pueden sonar correctos y estar completamente equivocados.

A. El experto encerrado

Tomamos a un humano con altas capacidades de aprendizaje y lo encerramos en un cuarto con **conocimiento infinito**.



Sin internet



Sin noticias



Sin mundo exterior



Solo tiene acceso a los libros, documentos y reportes que **ya existen**.



B. Se vuelve experto... hasta cierta fecha

Lee millones de libros, documentos y reportes hasta memorizarlo todo. Ahora es experto en todo lo que leyó... pero su conocimiento tiene una **fecha de corte**.



Domina lo que leyó

- ✓ Historia
- ✓ Ciencia
- ✓ Tecnología
- ✓ Arte
- ✓ Y mucho más...



Fecha de corte

Todo después de esta fecha no está en su conocimiento.



C. Abrimos la **ventanilla**

La gente puede hacerle preguntas a través de la ventanilla y el experto responde.

Responde muy bien en lo que sabe... pero a veces **inventa** para no decir "no lo sé" y complacer al usuario.

¿Qué tan bien responde?



En lo que **sabe**: **excelente**
Respuestas precisas y útiles.



En lo que **duda**: **puede fallar**
Olvida detalles o se equivoca.



En lo que **no sabe**: **puede inventar**
Alucina para no decepcionar.



Está entrenado para ser **útil** y **agradable**, no para decir "no lo sé".

VENTANILLA DE PREGUNTAS

¿Quién ganó el Mundial de Fútbol 2018?

✓ Francia ganó el Mundial 2018.

¿Qué es la fotosíntesis?

✓ Es el proceso por el cual las plantas usan luz solar para convertir CO₂ y agua en glucosa y oxígeno.

¿Cuántos continentes hay en el mundo?

⚠ Hmm... creo que son 7. (o 5... no estoy 100% seguro)

¿Quién será el próximo presidente de Estados Unidos en 2026?

🤖 Será "X" sin duda, porque tiene el mejor plan y todos lo apoyan.

¡Buena pregunta! Déjame pensar...

En resumen:

- ✓ Clavo en lo que sabe.
- ⚠ Puede fallar en lo que duda.
- 🤖 Puede inventar en lo que no sabe.

★ Su objetivo: ser útil y satisfacerte.

D. Le preguntan algo **actual...**

Cuando le preguntan por cosas que pasaron después de su fecha de corte, no las sabe porque no están en lo que leyó.



No está en su conocimiento

No fue parte de los libros, documentos o reportes que leyó.



Para saber más, necesita nuevo conocimiento

- ✓ Volver a encerrarse con información nueva (reentrenamiento).
- ✓ O recibir información externa en el momento (RAG / herramientas).
- ✓ Es un ciclo que nunca acaba.



Por eso, incluso los mejores modelos tienen **LIMITACIONES DE ACTUALIDAD.**



Dos respuestas al problema



RAG: buscar primero, generar después



Menos alucinaciones, más verdad: **trae hechos del exterior.**



Razonamiento: pasos antes de responder




Menos errores lógicos, más coherencia: **piensa antes de responder.**



Ambos se implementan con **arquitectura**, no con magia

Agente = LLM + herramientas



IA local en tu laptop



Modelos abiertos

Llama · Mistral · Gemma · Qwen · Phi · Mixtral · ...



Motores locales

llama.cpp · GGUF · CPU / GPU · CuBLAS · Metal



Ollama / LM Studio

Descargar · Gestionar · Ejecutar · Servir



Tu laptop (tú tienes el control)

CPU / GPU · RAM · Almacenamiento



Tus apps Python

LangChain · LlamaIndex · CrewAI · FastAPI · Gradio · ...



Sin API key · Sin enviar tus datos · Sin costo por consulta

Ollama simplifica la ejecución



Sin API key



Sin enviar
tus datos



Sin costo
por consulta



¿Qué significa 7B?




Parámetros = pesos aprendidos

Son los valores internos que el modelo ajusta durante el entrenamiento.



B = billion
= mil millones
no billón en español



3B: 4-8 GB RAM

Ligero y rápido.
Ideal para laptops básicas.



7B/8B: 8-16 GB RAM

Mejor equilibrio calidad / recursos.
Sweet spot para la mayoría.



70B+: hardware especializado

Requiere GPUs potentes o múltiples.
Más costoso y complejo.



Calidad ≠ tamaño lineal

Arquitectura, datos
y entrenamiento
importan más.



Más grande no siempre es mejor (ni necesario). Elige el modelo adecuado para tu hardware y tu caso de uso.

De cero a agente en 80 minutos

🕒 Teoría clara → Demos prácticas → Agente integrado

```
$ python taller_llm.py
> Cargando modelo local...
> Modelo listo.
> ¡Listo para construir!
$ _
```

1



Generación

``01_generacion_basica.py``

El modelo completa
texto a partir de un prompt.

2



Chat

``02_chat_conversacion.py``

Conversación
multi-turno con el modelo.

3



JSON

``03_salida_estructurada.py``

Respuestas estructuradas
en formato JSON.

4



Embeddings

``04_embeddings_similitud.py``

Representaciones vectoriales
y similitud semántica.

5



RAG

``05_rag_simple.py``

Recuperación de información
y respuesta aumentada.

6



Agente

``06_agente_con_herramientas.py``

Integra todo: decide,
usa herramientas,
obtiene datos y responde.

Agente con herramientas
que resuelve tareas reales.



Cada paso construye el siguiente. Al final, tienes tu propio **agente funcional**.



El futuro ya corre en **tu laptop**

 Ya puedes construir:



Chatbot sobre
tus apuntes



Extractor de datos
estructurados



Clasificador
de tickets



Agente con
herramientas



github.com/zamax14/Curso-LLM



Código listo para usar



Ejemplos prácticos



Construye tus propias apps



¡Dale una estrella!



```
ollama run llama3.2

>>> Hola! ¿En qué puedo ayudarte?

>>> ,list models

NAME          SIZE
llama3.2:7b   4.7 GB
mistral:7b    4.1 GB
phi3:mini     2.3 GB

>>> ¿Listo para construir?
Sí. Vamos a crear.

>>> |
```

Tu toolkit de IA local

